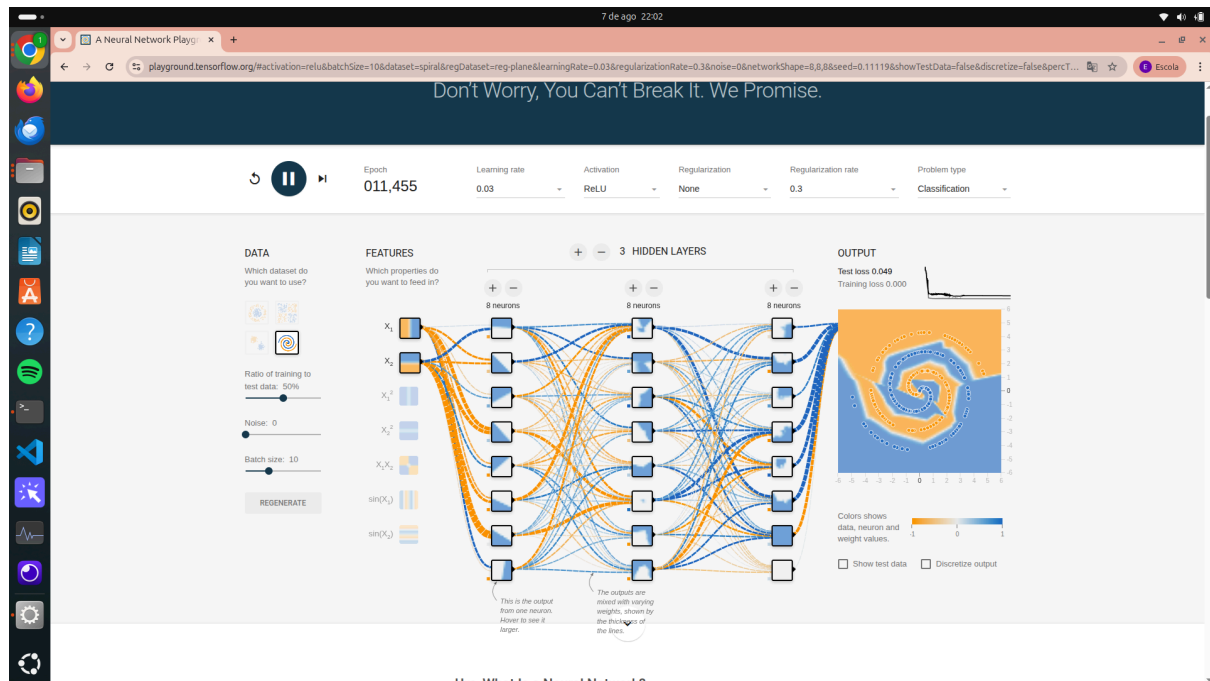


Nome: **Eric Cabral Neder**

E mail: [ecn@cesar.school](mailto:ecn@cesar.school)



Número de camadas (hidden layers): 3

- **Número de neurônios em cada camada:** 8 neurônios em cada uma das 3 camadas ocultas
- **Tipo de ativação:** ReLU
- **Learning rate:** 0.03

## 1. Número de camadas

- **Impacto:** Mais camadas aumentam a capacidade da rede de aprender padrões complexos, mas também elevam o risco de overfitting se não houver dados suficientes ou regularização. Poucas camadas podem simplificar demais o modelo, limitando sua precisão em problemas complexos.
- **Resumo:** Profundidade → maior capacidade de representação, mas maior risco de memorizar em vez de generalizar.

## 2. Número de neurônios em cada camada

- **Impacto:** Mais neurônios por camada permitem capturar mais detalhes e interações entre as variáveis, mas também aumentam a complexidade e o custo computacional. Poucos neurônios podem levar a underfitting, com a rede incapaz de aprender padrões mais sutis.
- **Resumo:** Largura → mais detalhes aprendidos, mas também mais chance de ruído e overfitting.

---

### 3. Tipo de ativação

- **Impacto:** A função de ativação define como a rede aprende relações não lineares.
  - **ReLU:** rápido e eficaz em redes profundas, evita saturação para valores positivos.
  - Funções como Sigmoid ou Tanh podem ter saturação e gradientes muito pequenos em redes profundas.
- **Resumo:** Escolha da ativação influencia velocidade de treino e capacidade de modelar relações complexas.

---

### 4. Learning rate

- **Impacto:** Taxa muito alta pode fazer o modelo “pular” a solução ótima e não convergir; muito baixa torna o treino lento e pode prender em mínimos locais. Um valor equilibrado acelera o aprendizado sem instabilidade.
- **Resumo:** Ajustar a taxa é essencial para equilibrar velocidade e estabilidade do treino.

---

### 5. Regularização (L1, L2, dropout)

- **Impacto:** Reduz overfitting ao penalizar pesos muito altos ou ao “desativar” neurônios durante o treino. Um valor muito alto pode prejudicar a capacidade de aprendizado, enquanto nenhum valor pode deixar o modelo superajustar aos dados de treino.
- **Resumo:** É o “freio” contra memorizar demais, forçando o modelo a generalizar.